

EventStoryLine 项目结构学习说明

面向 VS Code 阅读与二次开发的导览

yifeng_study

2026 年 5 月 7 日



图 1: 学习这个仓库时, 可以把它想成“语料数据 + 转换脚本 + 基线系统 + 评测”的组合。

目录

1	一句话理解这个项目	2
2	项目顶层目录	2
3	数据目录怎么读	3
3.1	annotated_data/: ESC 的 CAT/XML 标注	3
3.2	ECB+_LREC2014/: ECB+ 原始语料	3
3.3	evaluation_format/: 模型和评测最常用的格式	3
4	核心概念图	4
5	脚本职责	4
5.1	create_gold_document.py	4

目录	2
5.2 baseline_OP.py	5
5.3 baseline_PPMI1.py	5
5.4 baseline_PPMI_CONTAINS.py	5
5.5 eval_script.py	6
6 数据处理流程	6
7 当前仓库的数量感	7
8 推荐学习路线	7
9 VS Code 里怎么打开	7
10 速查：脚本输入输出	7
11 读代码时的几个提醒	8

1 一句话理解这个项目

EventStoryLine 仓库围绕 ESC（事件故事线语料库）和 ECB+ 语料展开，核心目标是支持新闻事件故事线中的事件关系抽取、数据格式转换、基线系统运行与结果评测。

从当前项目结构看，它不是一个典型 Web/App 工程，而更像一个**研究型 NLP 语料仓库**：

- 大量 XML/NAF/评测格式文件保存语料和标注。
- 少量 Python 脚本负责把 CAT XML 标注转换成评测格式。
- 基线脚本基于事件共现、PPMI、时间锚等启发式方法生成系统输出。
- 评测脚本比较标准答案文件与基线输出，计算精确率、召回率、F1。

2 项目顶层目录

当前仓库顶层最重要的内容如下：

路径	作用
README.md	项目说明、版本信息和引用论文。
LICENSE.md	许可证文件。
ECB+_LREC2014/	原始 ECB+ 相关材料, 包括 ECB+ XML、README、license 和压缩包。
annotated_data/	ESC 的 CAT/XML 标注数据，按版本和 topic 组织。
evaluation_format/	已转换好的评测格式数据，分全语料和测试语料。
ecb+_naf/	ECB+ 的 NAF 版本文件，基线脚本中用于读取 lemma、句子等语言学信息。
ppmi_events_ecb+_test/	PPMI 基线相关的事件数据或中间测试材料。
create_gold_document.py	从 ECB+ 与 ESC CAT XML 合并生成评测格式标准答案文件。
baseline_OP.py	简单共现基线：同一句事件两两成对。
baseline_PPMI1.py	使用 PPMI 的故事线基线。
baseline_PPMI_CONTAINS.py	在 PPMI 基础上加入时间锚 CONTAINS 限制的基线。
eval_script.py	对系统输出和标准答案进行精确率、召回率、F1 评测。
yifeng_study/	本学习文档所在目录。




图 2: 顶层结构可以粗略分为数据、脚本、学习文档三块。

3 数据目录怎么读

3.1 annotated_data/: ESC 的 CAT/XML 标注

这个目录保存 ESC 的人工/众包故事线标注，当前有多个版本：

- v0.9: 早期版本。
- v1.0: 专家标注版本。
- v1.5: 专家 + 众包扩展版本，README 中说明了 origin 和 validated 等属性。

其下再按 topic 编号划分，例如：

```
annotated_data/v1.5/22/22_3ecbplus.xml.xml
annotated_data/v1.5/14/14_11ecbplus.xml.xml
```

注意文件名里常见 .xml.xml，这是仓库已有数据命名，不是 LaTeX 或 VS Code 的问题。

3.2 ECB+_LREC2014/: ECB+ 原始语料

create_gold_document.py 会同时读取：

- ECB+ 原始 CAT 文件，用于事件提及和共指链；
- ESC 标注文件，用于 PLOT_LINK 关系；
- 然后把共指扩展后的事件关系写到评测格式文件。

3.3 evaluation_format/: 模型和评测最常用的格式

这个目录已经把 XML 标注转换成更容易评测的 TSV 风格文本行。主要分两大块：

- full_corpus/: 全语料评测格式。
- test_corpus/: 测试集评测格式。

每个版本下面常见两个子目录：

- `coref_chain/`: 共指链扩展后的事件链关系。
- `event_mentions_extended/`: 扩展到事件提及对级别的事件关系。

评测格式的一行一般类似:

```
event_token_ids_source event_token_ids_target RELATION_TYPE
```

4 核心概念图




图 3: 文档、事件提及、共指、情节链接和故事线之间的直观关系。




图 4: 这个项目关心的不是普通实体分类，而是事件之间如何组成故事线。

5 脚本职责

5.1 `create_gold_document.py`

这个脚本是理解数据流的入口。它把 ECB+ 与 ESC 两边的信息合并，生成评测用标准答案文件。

主要函数:

函数	作用
<code>extract_event_CAT</code>	从 CAT XML 的 Markables 中抽取 ACTION / NEG_ACTION 类事件。
<code>extract_corefRelations</code>	从 ECB+ Relations 中抽取事件共指链。
<code>extract_plotLink</code>	从 ESC XML 中抽取 PLOT_LINK 关系及其 relType。
<code>create_merged_files</code>	把共指扩展应用到情节链接，写出两个评测文件。
<code>merge_annotations</code>	遍历 topic 文件夹，批量调用合并逻辑。

运行方式:

```
python3 create_gold_document.py ECBplusTopic ECBstarTopic outfolder
```

5.2 baseline_OP.py

这是最容易读懂的基线脚本。它假设:

- 事件已经被正确识别;
- 同一句子中的事件两两之间都有 PLOT_LINK;
- 过滤掉 reporting、causative、aspectual 等不适合的事件类别;
- 输出关系默认写成 PRECONDITION。

它适合当作你阅读代码的第一站，因为逻辑从 XML 解析到事件配对非常直接。

5.3 baseline_PPMI1.py

这个基线更像研究实验脚本。它读取 CAT 与 NAF:

- CAT 提供事件提及和 token id。
- NAF 提供 lemma、句子编号等语言学信息。
- 使用事件 lemma 的共现统计计算 PPMI。
- 用 PPMI 阈值筛选候选事件对。

5.4 baseline_PPMI_CONTAINS.py

这个脚本继承 PPMI 思路，但额外利用 TLINK 中的 CONTAINS 时间锚关系。它的直觉是：如果事件共享某个时间锚，可能更值得考虑为故事线关系候选。

5.5 eval_script.py

评测脚本读取标准答案与系统输出，计算两种层面的指标：

- 事件对层面：只看事件对是否匹配。
- 事件对 + 关系类型层面：事件对和关系类型都要匹配。

运行方式：

```
python3 eval_script.py gold_dir system_dir
```

6 数据处理流程




图 6: 推荐按这条路径理解代码：先看标准答案如何生成，再看基线如何输出，最后看评测如何计分。

7 当前仓库的数量感

下面是写文档时对当前工作区做的粗略文件计数，帮助你判断哪里是大头：

目录	文件数	阅读优先级
annotated_data/	1103	中：了解数据结构即可，不必逐个读。
ECB+_LREC2014/	990	中：原始语料，主要配合脚本理解。
evaluation_format/	2602	高：评测输入和输出最常用。
ecb+_naf/	272	中：PPMI 基线需要。
ppmi_events_ecb+_test/	224	低到中：基线相关材料。

8 推荐学习路线

1. 先读 README.md，弄清楚 ESC v1.0、v1.2、v1.5 的差异。
2. 打开 evaluation_format/test_corpus/v1.5/event_mentions_extended/ 里的任意文件，看三列格式。
3. 读 eval_script.py，因为它最短，能快速说明系统输出应该长什么样。
4. 读 baseline_OP.py，理解“同句事件两两配对”的最朴素基线。
5. 再读 create_gold_document.py，理解 XML 标注如何变成评测格式。
6. 最后读 baseline_PPMI1.py 和 baseline_PPMI_CONTAINS.py，它们更偏实验细节。

9 VS Code 里怎么打开

建议在 VS Code 中打开整个仓库目录：

```
code /Users/luyifeng/Documents/GitHub/EventStoryLine
```

然后重点看：

```
yifeng_study/project_structure_guide.tex
yifeng_study/assets/
README.md
eval_script.py
baseline_OP.py
create_gold_document.py
```

如果安装了 LaTeX Workshop 插件，可以用 XeLaTeX 编译本文档。中文文档建议使用 `xelatex`，不要用普通 `pdflatex`。

10 速查：脚本输入输出

脚本	输入	输出/作用
<code>create_gold_document.py</code>	ECB+ 主题目录、ESC 主题目录、输出目录	标准答案评测格式文件。
<code>baseline_OP.py</code>	ECB+ 主题目录、输出目录	<code>*.base.out</code> 系统输出。
<code>baseline_PPMI1.py</code>	CAT/NAF/PPMI 相关输入	PPMI 筛选后的事件关系输出。
<code>baseline_PPMI_CONTAINS.py</code>	CAT/NAF/时间锚相关输入	加入 CONTAINS 限制的 PPMI 输出。
<code>eval_script.py</code>	标准答案目录、系统输出目录	事件对层面与关系类型层面的精确率、召回率、F1。

11 读代码时的几个提醒

- 这个仓库代码年份较早，有些 lxml API 如 `getchildren()` 在新版本里可能会有兼容性提醒。
- 脚本大量使用追加写入 "a"，重复运行同一个输出路径可能导致结果叠加；学习时最好输出到新的临时目录。
- 文件名包含 +、下划线和双扩展名，命令行里路径要小心复制完整。
- 基线不是深度学习模型，而是用于论文实验的启发式系统。